

PLATEFORME DATA-DRIVEN

Cahier des charges (v2) · Rapport global · Bilan de projet

Pricing & Recommandation — projet DATA-PRICE

pour un e-commerce local — prévision de la demande, simulation de remise et recommandations personnalisées



Nom de code du projet	DATA-PRICE
Nature du document	Document maître unique — regroupe le cahier des charges, le rapport global et le bilan de projet
Cheffe de projet / Product Owner	Marie SOW
Équipe projet	Marie Sow · Mozart Gildas Codjo · Younes Hachami · Fatoumata Siby
Sponsor / Commanditaire	M. Nawal Dine Touré (enseignant-référent)
Date de diffusion	22 août 2026
Statut	Livrable final — clôture administrative le 20/08 ; finalisation technique jusqu'au 22/08 (voir ch. 17)

Sommaire

Sommaire	2
Synthèse	5
1. Note de cadrage de la cheffe de projet	6
2. Contexte, enjeux et justification	6
2.1 Contexte métier	6
2.2 Enjeux	6
2.3 Justification (pourquoi un projet data)	6
3. Objectifs du projet (SMART)	7
4. Périmètre du projet	8
4.1 Inclus dans le périmètre (in scope)	8
4.2 Hors périmètre (out of scope)	8
5. Livrables attendus et responsables	8
6. Cahier des charges détaillé	9
6.1 Exigences fonctionnelles (MVP)	9
6.2 Exigences techniques (stack conseillée M2)	9
6.3 Exigences non fonctionnelles	9
7. Équipe, rôles et gouvernance	10
7.1 Rôles et responsabilités	10
7.2 Instances et rythme de pilotage	10
7.3 Outils de collaboration	11
8. Matrice des responsabilités (RACI)	12
9. Méthodologie de conduite du projet	12
9.1 Une démarche itérative et incrémentale	13
9.2 Démarche qualité & relecture croisée	13
10. Découpage du projet (WBS — Work Breakdown Structure)	14
11. Planning, jalons et diagramme de Gantt	16
11.1 Jalons clés (milestones)	16
11.2 Diagramme de Gantt (11 → 22 août 2026)	16
12. Suivi de l'avancement (Trello)	19
13. Vue d'ensemble de la solution	20
14. Lots 2 & 3 — Architecture & données	20

14.1 Le data lake : zones et responsabilités	20
14.2 Le data warehouse : schéma en étoile	21
14.3 Évolution du schéma : de la v1 à la v4	22
14.4 Choix techniques et volumétrie	22
15. Lot 4 — Qualité des données & catalogage	23
16. Lot 5 — Modélisation data science	23
16.1 Prévision de la demande	23
16.2 Tarification — simulation des conséquences d'une remise	24
16.3 Recommandation	24
16.4 Bilan des modèles retenus	25
17. Démarche itérative & livraisons par version	25
17.1 Le cycle audit → correction → contre-audit	26
17.2 Livraisons par version	26
17.3 Le durcissement des deux journaux (v1 → v4)	27
17.4 Historique des versions des modèles (V1 → V4)	28
17.5 Les quatre audits de validité	28
18. Lot 6 — Industrialisation (API & MLOps)	29
18.1 API & console web	29
18.2 Tests, reproductibilité & MLOps	29
18.3 Déploiement	29
19. Lot 7 — BI, KPI & dashboard décisionnel	30
19.1 Filtres et sécurité par profil (RLS) — politique cible	31
20. Business case & retour sur investissement	32
20.1 KPI métier — hypothèses ex-ante	32
21. Gestion des risques	32
22. Conformité RGPD & protection des données	34
22.1 Principe directeur	34
22.2 Mesures RGPD	34
23. État d'avancement à la livraison	35
24. Enseignements & retour d'expérience	35
25. Limites assumées & perspectives (v2)	35
25.1 Limites des données	35

25.2 Limites du service	36
25.3 Perspectives (version 2)	36
26. Alignement sur la grille d'évaluation	36
27. Conclusion	36
Annexe A — Dictionnaire de données (schéma en étoile)	38
A.1 — fact_ventes · grain : un produit vendu dans une commande	38
A.2 — fact_evenements_web · grain : un événement de navigation	38
A.3 — fact_stock · grain : niveau de stock d'un produit en fin de journée	38
A.4 — fact_experimentation_prix (v4) · grain : une décision de prix, un produit, une semaine	39
A.5 — fact_exposition_reco (v4) · grain : une recommandation affichée à un visiteur (slate)	39
A.6 — Dimensions (produit, client, date, promotion)	40
Annexe B — Guide « quelles tables pour quel modèle »	40
Annexe C — Registre des risques (rappel)	41
Annexe D — Cadence de référence (projet 10-12 semaines)	41
Annexe E — Glossaire	41

Synthèse

DATA-PRICE est une plateforme d'aide à la décision pour un e-commerce local d'Afrique de l'Ouest (prix en FCFA). Elle vise trois leviers de valeur — anticiper la demande pour éviter ruptures et surstocks, éclairer les décisions de remise en simulant leurs conséquences, et recommander le bon produit au bon client — traduits en trois cas d'usage data : la prévision de la demande, la simulation de remise et la recommandation.

La solution repose sur une architecture en deux couches : un data lake organisé en zones successives (Raw → Bronze → Silver → Gold) et un entrepôt de données en schéma en étoile, hébergé sur Supabase (PostgreSQL). Le schéma, initialement conçu autour de trois tables de faits, a été enrichi au cours du projet à cinq tables de faits et quatre dimensions, pour répondre aux besoins remontés par l'équipe data science. Les modèles ont été développés et évalués sur la couche Gold ; une API dockerisée et un dashboard décisionnel en restituent les résultats.

Le projet a été conduit selon une double référence méthodologique : le PMBOK pour la gestion de projet (cadrage, planification, maîtrise des risques, surveillance) et une démarche itérative de type CRISP-DM pour la partie data. Cette itération est un trait marquant du projet : chaque livrable a été produit en plusieurs versions successives (le modèle de données est passé par quatre versions, v1 → v4), chacune corrigeant la précédente à la suite d'un audit par les pairs, avec un lineage tracé et reproductible (chapitre 17). L'équipe de quatre personnes s'est appuyée sur un socle d'outils partagés — Slack, Trello, GitHub, Supabase — assurant traçabilité, visibilité de l'avancement et reproductibilité.

À la livraison, l'ensemble des lots du projet est réalisé : cadrage et gouvernance, architecture et jeu de données, ingestion et entreposage, contrôles de qualité, modélisation data science (prévision, simulation de remise, recommandation), industrialisation (API dockerisée, MLOps) et restitution BI. Les modèles ont été entraînés et évalués par rapport à leurs baselines. Les données étant synthétiques et le déploiement académique, aucun résultat ne constitue une performance commerciale réelle et aucun effet causal n'est estimé ; les métriques sont présentées telles que mesurées hors ligne.

Dimension	Élément clé	État
Cadrage & gouvernance	Cahier des charges, WBS 7 lots, RACI, planning, registre des risques	Réalisé
Architecture & données	Data lake 4 zones + entrepôt en étoile (5 faits, 4 dimensions)	Réalisé
Ingestion & entreposage	Chargement de la couche Gold sur Supabase (PostgreSQL)	Réalisé
Qualité & catalogage	Anomalies injectées + règles great_expectations	Réalisé
Modélisation data science	Prévision, simulation de remise, recommandation	Réalisé
Industrialisation (API/MLOps)	API FastAPI dockerisée, 147 tests, reproductibilité (seed, SHA-256)	Réalisé
BI & business case	Dashboard décisionnel, KPI, ROI, rapport business	Réalisé

PARTIE I

Cadrage & spécifications

Le « quoi » : contexte, objectifs, périmètre et exigences — cahier des charges de référence

1. Note de cadrage de la cheffe de projet

Le présent dossier constitue le livrable de référence du projet DATA-PRICE. Il formalise le cadrage, le périmètre, l'organisation, la planification et la maîtrise des risques du projet, conformément au référentiel PMBOK® (phases Démarrage et Planification) et aux bonnes pratiques de gestion des projets data (approche itérative de type CRISP-DM / TDSP). Il sert de référence interne pour l'équipe et de base de pilotage jusqu'à la livraison finale du 20 août 2026, puis de compte rendu complet une fois le projet mené à son terme.

2. Contexte, enjeux et justification

2.1 Contexte métier

L'entreprise est un acteur du commerce en ligne local, actif en Afrique de l'Ouest (prix en FCFA). Son catalogue couvre plusieurs centaines de références réparties en huit familles de produits, pour une base de plusieurs milliers de clients. Les ventes sont fortement saisonnières (pics de fin d'année, effet week-end) et sensibles aux promotions. Aujourd'hui, les décisions de prix, de réapprovisionnement et de mise en avant des produits reposent surtout sur l'expérience et l'historique, sans exploitation systématique des données transactionnelles et comportementales pourtant disponibles. Le projet vise à combler cet écart en dotant l'entreprise d'une plateforme data d'aide à la décision.

2.2 Enjeux

- **Enjeu économique** : préserver la marge et augmenter le chiffre d'affaires par un meilleur pilotage des remises et le up/cross-sell.
- **Enjeu opérationnel** : réduire ruptures et surstocks via une meilleure prévision de la demande.
- **Enjeu client** : améliorer l'expérience et la fidélisation par la personnalisation.
- **Enjeu de conformité** : exploiter les données comportementales dans le respect du RGPD et de la protection de la vie privée.

2.3 Justification (pourquoi un projet data)

Les leviers visés — anticiper la demande, éclairer les décisions de remise et recommander le bon produit au bon client — relèvent tous de problèmes prédictifs qui ne peuvent être traités efficacement de façon manuelle. Ils supposent d'apprendre des régularités à partir d'un grand volume de données (transactions, navigation web, promotions) puis de les industrialiser dans des traitements reproductibles. C'est précisément l'objet d'un projet data : transformer des données brutes en aides à la décision mesurables (prévisions, simulations, recommandations), tout en garantissant la qualité des données, la conformité RGPD et le suivi de la performance des modèles. La démarche est donc justifiée à la fois par la valeur métier attendue et par la nature intrinsèquement data des problèmes à résoudre.




Illustration — Maquette de la plateforme cible : remises affichées (badges), recommandations personnalisées et anticipation du stock.

3. Objectifs du projet (SMART)

#	Objectif	Indicateur de succès
O1	Construire un pipeline d'ingestion (batch + streaming simulé) des données transactions, produits, logs web et promotions.	Pipeline reproductible ; données chargées dans le data lake et le data warehouse.
O2	Mettre en place un entrepôt de données (data lake Parquet + data warehouse) avec contrôles qualité.	Schéma documenté ; règles de data quality exécutées (great_expectations).
O3	Développer des modèles : prévision de la demande, simulation des conséquences d'une remise, recommandation.	Modèles entraînés + évaluation vs baseline (métriques documentées).
O4	Exposer une API dockerisée retournant recommandations, prévisions et simulation de remise.	Endpoint fonctionnel testé ; conteneur Docker opérationnel.
O5	Livrer un dashboard décisionnel et un rapport business (ROI, risques, plan de déploiement).	Dashboard interactif (KPI) + rapport stratégique validés.
O6	Garantir la conformité RGPD et la protection des données.	Mesures RGPD documentées (minimisation, pseudonymisation, registre).

4. Périmètre du projet

4.1 Inclus dans le périmètre (in scope)

- Génération et documentation d'un jeu de données synthétique (transactions, produits, logs, promotions).
- Pipeline ETL batch + streaming simulé ; data lake (Parquet) + data warehouse (PostgreSQL / DuckDB).
- Contrôles de qualité et catalogage minimal (profiling, règles).
- Modèles de prévision (LightGBM, Croston), de simulation de remise (baseline médiane produit) et de recommandation (rankers CatBoost/LightGBM, popularité).
- API microservice (FastAPI + Docker) exposant prix et recommandations.
- Dashboard décisionnel (KPI marge, rotation stock, conversion, CLTV) + rapport business.
- Documentation, dépôt de code et dossier de projet complet (le présent document).

4.2 Hors périmètre (out of scope)

- Déploiement en production réelle sur l'infrastructure de l'entreprise (simulation uniquement).
- Intégration à un ERP / CRM de production réel.
- Collecte de données personnelles réelles (travail sur données synthétiques).
- Extensions bonus (A/B testing temps réel, churn/CLTV avancé, XAI poussé) — traitées seulement si le planning le permet.

5. Livrables attendus et responsables

Livable	Responsable principal	Échéance
L1 — Cahier des charges & planning (WBS, Gantt, risques, RGPD)	Marie (Cheffe de projet)	11/08
L2 — Architecture technique + schéma de données	Mozart (Data Engineer)	13/08
L3 — Jeu de données synthétique documenté + scripts d'ingestion	Mozart (Data Engineer)	13/08
L4 — Pipeline ETL / notebooks reproductibles	Mozart (Data Engineer)	14/08
L5 — Modèles entraînés + évaluation (métriques, baselines)	Younes (Data Scientist)	16/08
L6 — API dockerisée (recommandations / simulation de remise) + MLOps	Younes (Data Scientist)	17/08
L7 — Dashboard interactif & rapport business (KPI, ROI, mise en prod)	Fatoumata (BI Analyst)	19/08
L8 — Dossier de projet complet + dépôt de code	Marie + toute l'équipe	20/08

Le livrable L8 consolide l'ensemble du projet en un dossier documentaire complet et autoportant, accompagné du dépôt de code.

6. Cahier des charges détaillé

6.1 Exigences fonctionnelles (MVP)

- **EF1** : Ingérer les données transactions, produits, logs web et promotions en batch et en streaming simulé.
- **EF2** : Stocker les données brutes en data lake (Parquet) et les données modélisées en data warehouse.
- **EF3** : Exécuter des contrôles de qualité (complétude, unicité, cohérence, fraîcheur) et un catalogage minimal.
- **EF4** : Prévoir la demande par produit sur un horizon glissant.
- **EF5** : Simuler les conséquences (volume, chiffre d'affaires, marge) d'une remise, sans prétention causale.
- **EF6** : Recommander des produits (cross-sell / up-sell) via une approche hybride.
- **EF7** : Exposer prix et recommandations via une API REST.
- **EF8** : Restituer les KPI décisionnels dans un dashboard interactif.

6.2 Exigences techniques (stack conseillée M2)

Brique	Technologies retenues
Ingestion / ETL	Python, PySpark, streaming simulé (ou Kafka)
Stockage	Data Lake : MinIO / S3 (Parquet) — Data Warehouse : PostgreSQL / DuckDB (BigQuery / Redshift simulés)
Orchestration	Airflow ou Prefect
Data science	scikit-learn, LightGBM, CatBoost, Croston (séries intermittentes)
Recommandation	rankers d'apprentissage (CatBoostRanker, LightGBM), modèle de conversion, popularité (repli)
API / Déploiement	FastAPI, Docker, GitHub Actions (CI/CD), MLflow (suivi des modèles)
Dashboard	Metabase / Superset / Power BI / Dash / Streamlit
Tests & qualité	pytest, great_expectations

6.3 Exigences non fonctionnelles

- **Qualité des données** : règles de validation exécutées à chaque exécution du pipeline ; taux de complétude cible $\geq 95\%$.
- **Reproductibilité** : notebooks et pipelines versionnés (Git), environnement conteneurisé, seeds fixés.
- **Performance** : temps de réponse API < 500 ms sur requête de recommandation / prix.
- **Sécurité & confidentialité** : données synthétiques ; secrets hors du dépôt ; accès au dépôt maîtrisé.
- **Conformité** : respect du RGPD et de la protection des données (voir Partie IV).
- **Traçabilité** : suivi des expériences et des versions de modèles (MLflow).

PARTIE II

Organisation, gouvernance & pilotage

Le « comment on s'est organisés » : équipe, méthode, outils, planning et suivi

7. Équipe, rôles et gouvernance

7.1 Rôles et responsabilités

Membre	Rôle	Responsabilités principales
Marie Sow	Cheffe de projet / Product Owner	Cadrage, cahier des charges, planning, pilotage, gestion des risques, communication, coordination des livrables, consolidation du dossier final.
Mozart Codjo	Data Engineer	Architecture, jeu de données synthétique, ingestion, data lake / warehouse, ETL, data quality, enrichissement des données.
Younes Hachami	Data Scientist & MLOps	Prévision, simulation de remise, recommandation, évaluation vs baselines ; API, conteneurisation Docker, tests et déploiement.
Fatoumata Siby	BI / Business Analyst	KPI, dashboard décisionnel, business case, ROI, contribution au rapport stratégique.

Décision d'organisation. Le rôle MLOps, non attribué nominativement au départ (l'équipe compte quatre personnes pour cinq rôles types), a finalement été porté par le Data Scientist, qui a réalisé l'API, la conteneurisation, les tests et le déploiement. Cette clarification figure au registre des risques (R4).

7.2 Instances et rythme de pilotage

Compte tenu du calendrier resserré, la cheffe de projet a mis en place un dispositif de pilotage à deux vitesses : un suivi léger au quotidien pour la fluidité, et un point de mise au point plus formel tous les deux jours pour la maîtrise du projet. Ce rythme a permis de détecter tôt les difficultés et d'arbitrer sans attendre les jalons.

Instance	Fréquence	Objet
Réunion de lancement	11/08 (J0)	Validation du cahier des charges et du planning ; répartition des rôles ; mise en place des outils (Slack, Trello, GitHub, Supabase).
Point court quotidien	Chaque jour (Slack)	Point d'avancement asynchrone de 10 min max : ce qui a été fait, ce qui est

		prévu, blocages éventuels.
Point de mise au point	Tous les 2 jours (Meet)	Réunion de synchronisation menée par la cheffe de projet — cœur du pilotage (voir détail ci-dessous).
Revue de jalon	Sur J1, J2, J3	Démonstration de l'incrément produit et validation du franchissement du jalon.
Revue de clôture	19-20/08	Répétition générale, tests d'intégration, contrôle final et consolidation du dossier de livraison.

Le point de mise au point, tenu tous les deux jours, est l'instance de pilotage principale. La cheffe de projet y déroule un ordre du jour constant :

- **Revue des livrables** — revue des livrables attendus à échéance — chaque responsable présente l'état de sa production (fait, en cours, reste à faire) au regard du planning.
- **Où en est le projet** — point d'avancement par lot WBS, confronté au diagramme de Gantt et au tableau Trello, afin de situer le projet sur son chemin critique (Données → Modèles → API / Dashboard → Livraison).
- **Points bloquants** — identification des effets handicapants et des points bloquants — dépendances non levées, données manquantes, tâche sous-estimée, disponibilité inégale — et évaluation de leur gravité.
- **Arbitrages** — décisions et arbitrages de la cheffe de projet : re-priorisation, réaffectation d'une tâche, activation d'un binôme de secours, report d'un bonus hors périmètre MVP, ajustement d'échéance.
- **Traçabilité** — consignation de la décision et du responsable dans le journal de suivi, pour la traçabilité et le point suivant.

Exemple concret. Le retour de l'équipe data science du 18 août (données d'expérimentation et d'exposition manquantes) a été porté en point de mise au point : la gravité a été évaluée, l'arbitrage d'enrichir le schéma plutôt que de contourner a été acté, et la tâche a été réaffectée à l'équipe data engineering — décision tracée et exécutée avant le jalon suivant. Le journal des points quotidiens et des arbitrages figure dans le classeur de suivi (onglet « Suivi » du planning).

7.3 Outils de collaboration

La collaboration de l'équipe s'appuie sur un socle d'outils partagés : Slack pour la communication et les notifications (canal #projet-nawal), Trello pour le suivi des tâches en Kanban — connecté à Slack pour remonter automatiquement l'avancement, Supabase (PostgreSQL) pour héberger le data warehouse, GitHub pour le versionnement du code et l'intégration continue, et Google Meet pour les points de synchronisation. Cette combinaison assure la traçabilité des décisions, la visibilité de l'avancement et la reproductibilité des livrables.

Outil	Usage dans le projet
Slack (#projet-nawal)	Communication d'équipe, notifications, points quotidiens asynchrones.
Trello (Kanban)	Suivi des tâches par lot WBS — connecté à Slack pour la remontée automatique.
GitHub	Versionnement du code, notebooks, intégration continue (CI/CD).

Supabase (PostgreSQL)	Hébergement managé du data warehouse (schéma en étoile, couche Gold).
Google Meet	Réunions de synchronisation (lancement, revues de sprint, clôture).

8. Matrice des responsabilités (RACI)

R = Réalise · A = Approuve (redevable) · C = Consulté · I = Informé.

Activité / Livrable	Marie	Mozart	Younes	Siby
Cadrage & cahier des charges	R/A	C	C	C
Planning & suivi des risques	R/A	I	I	I
Architecture & schéma de données	A	R	C	I
Jeu de données & ingestion	A	R	C	I
Pipeline ETL & data quality	A	R	C	I
Modèles (prévision/simulation /reco)	A	C	R	C
API dockerisée & MLOps	A	I	R	I
Dashboard & business case	A	I	C	R
Rapport stratégique (ROI, risques)	A/C	C	C	R
Dossier final & restitution	R/A	R	R	R

9. Méthodologie de conduite du projet

Le projet articule deux référentiels complémentaires. Le PMBOK® structure la gestion de projet à proprement parler : le démarrage (note de cadrage, identification des parties prenantes), la planification (WBS, planning, budget de charge, registre des risques), l'exécution (production des livrables), et la surveillance & maîtrise (suivi de l'avancement, gestion des changements de périmètre). En parallèle, la partie data suit une démarche itérative de type CRISP-DM : compréhension métier, compréhension et préparation des données, modélisation, évaluation, puis déploiement.

Concrètement, cette double lecture se traduit par un enchaînement de phases — cadrage, données, modélisation, industrialisation, restitution — dont plusieurs sont menées en parallèle pour tenir l'échéance. Le

chemin critique du projet passe par la disponibilité des données (jalon J1), sans laquelle ni la modélisation ni la BI ne peuvent progresser.

Cadence réelle vs cadence de référence. Un vrai projet de ce type se déroulerait sur 10 à 12 semaines en sprints bi-hebdomadaires (voir Annexe F). Compte tenu de l'échéance académique, le cycle a été compressé en un sprint intensif (11 → 20 août), prolongé jusqu'au 22 août pour la finalisation technique.

9.1 Une démarche itérative et incrémentale

Au-delà de l'enchaînement des phases, le projet a été conduit de façon nettement itérative : chaque livrable a connu plusieurs versions successives, chacune corrigeant ou enrichissant la précédente à la lumière d'un contrôle par les pairs. Concrètement, l'équipe data science a systématiquement audité, en lecture seule, les livraisons de l'équipe data engineering, puis renvoyé une liste précise d'anomalies et de demandes d'amélioration — donnant lieu à une nouvelle version, elle-même contre-auditée. Ce cycle audit → correction → contre-audit s'est répété du 14 au 21 août et constitue le cœur de la dynamique d'amélioration continue du projet.

Amélioration continue & traçabilité. Cette boucle a notamment fait passer le modèle de données par quatre versions successives (v1 → v4). À partir de la v3, chaque version est tracée (script générateur, seed, empreinte SHA-256 reproductible), ce qui rend les livrables auditable et rejouables à l'identique. Le détail des livraisons par version et des améliorations apportées figure au chapitre 17.

9.2 Démarche qualité & relecture croisée

La qualité des livrables a été traitée comme un processus à part entière, piloté par la cheffe de projet, et non comme une vérification de dernière minute. Ce dispositif repose sur trois piliers, appliqués à chaque production de l'équipe.

- **Definition of Done** — un livrable n'est déclaré « Terminé » que s'il satisfait des critères d'acceptation explicites (cohérence avec les autres documents, absence d'affirmation non sourcée, terminologie et attributions alignées, annexes reflétant la dernière version livrée).
- **Source de vérité** — un glossaire et un registre partagés (noms des modèles, métriques, outils, versions) tiennent lieu de source de vérité unique, afin d'éviter la dérive de vocabulaire d'un document à l'autre.
- **Relecture croisée** — chaque livrable est audité par un pair avant intégration. La boucle d'audit indépendant entre la data science et la data engineering (chapitre 17) en est l'illustration la plus aboutie ; le principe a été étendu à l'ensemble des documents du projet.

Concrètement, une liste de contrôle est déroulée avant toute remise :

#	Point de contrôle avant remise	Statut
1	WBS = Gantt = Trello = RACI : mêmes lots, mêmes libellés.	Vérifié
2	Chaque chiffre et chaque affirmation est traçable à une source réelle.	Vérifié
3	Aucune valeur inventée n'est présentée comme un résultat (maquettes clairement identifiées).	Vérifié

4	Terminologie identique partout (modèles, KPI, outils, noms de version).	Vérifié
5	Dates, attributions de rôles et responsabilités cohérentes de bout en bout.	Vérifié
6	Les annexes reflètent la dernière version livrée du schéma et des modèles.	Vérifié

Une gouvernance qui se voit dans le produit. Ce dispositif explique que plusieurs points aient été détectés et corrigés en cours de route (fuites de cible, alignement de l'annexe sur le schéma v4, clarification des attributions, retrait de toute affirmation non fondée). Loin d'être une faiblesse, cette capacité à repérer et à corriger avant la remise est précisément ce qu'une relecture croisée rigoureuse est censée produire.


10. Découpage du projet (WBS — Work Breakdown Structure)

Le WBS décompose le projet en sept lots de travail, eux-mêmes détaillés en tâches assignables. Il sert de base au diagramme de Gantt et à la répartition des responsabilités. Les sept lots ci-dessous constituent la colonne vertébrale de tout le dossier.

Lot	Tâches (niveau 2)	Resp.
1. Cadrage & gestion de projet	1.1 Charte & cahier des charges · 1.2 WBS & planning · 1.3 Registre des risques · 1.4 Plan RGPD · 1.5 Suivi & reporting	Marie
2. Architecture & données	2.1 Architecture technique · 2.2 Schéma de données · 2.3 Jeu de données synthétique documenté	Mozart
3. Ingestion & entreposage	3.1 Ingestion batch · 3.2 Streaming simulé · 3.3 Data lake (Parquet) · 3.4 Data warehouse	Mozart
4. Qualité & catalogage	4.1 Profiling · 4.2 Règles de qualité (great_expectations) · 4.3 Catalogage minimal	Mozart
5. Modélisation Data Science	5.1 Prévision de la demande · 5.2 Simulation de remise · 5.3 Recommandation · 5.4 Évaluation vs baselines	Younes
6. Industrialisation (API/MLOps)	6.1 API FastAPI · 6.2 Dockerisation · 6.3 Reproductibilité (seed, SHA-256) · 6.4 Tests	Younes
7. BI, business case & restitution	7.1 KPI & dashboard · 7.2 Business case & ROI · 7.3 Rapport stratégique · 7.4 Restitution & dossier final	Siby + Marie

ORGANIGRAMME DES TÂCHES (WBS) — PROJET DATA-PRICE

Plateforme Data-Driven Pricing & Recommendation | Cheffe de projet : Marie Sow | Découpage en 7 lots (cf. cahier des charges §9)



WBS à 2 niveaux (Lots → Tâches) · conforme PMBOK (phase Planification) et au cahier des charges · ISM Master 2 Big Data

Figure 1 — Organigramme des tâches (WBS) à deux niveaux : 7 lots → tâches.

11. Planning, jalons et diagramme de Gantt

Le projet réel est conçu en sprints bi-hebdomadaires sur 10 à 12 semaines (voir Annexe F). Compte tenu de l'échéance académique du 20 août 2026, le planning opérationnel ci-dessous compresse le cycle en un sprint intensif (11 → 20 août), prolongé de deux jours pour la finalisation technique (jusqu'au 22 août), structuré selon les phases PMBOK et la démarche CRISP-DM.

11.1 Jalons clés (milestones)

Jalon	Date	Critère de franchissement
J0 — Lancement & cadrage validé	Mar 11/08	Cahier des charges et planning approuvés par l'équipe.
J1 — Données prêtes	Jeu 13/08	Dataset + pipeline + data warehouse opérationnels et contrôlés.
J2 — Modèles v1 + maquette dashboard	Sam 15/08	Prévision/simulation/reco entraînés ; premières métriques ; maquette KPI.
J3 — Intégration API + dashboard	Lun 17/08	API dockerisée fonctionnelle ; dashboard connecté.
J4 — Rapport, tests & répétition	Mer 19/08	Rapport business finalisé ; tests passés ; répétition.
J5 — Clôture du sprint (échéance)	Jeu 20/08	Livrables déposés ; clôture administrative du projet.
J6 — Finalisation technique & dossier consolidé	Sam 22/08	Audit V4, correctif product_impressions, 147 tests, API en ligne ; dépôt du dossier consolidé.

Précision de calendrier : le jalon J5 (20/08) correspond à la clôture administrative du projet et au dépôt des livrables. La finalisation technique côté data science / MLOps (audit V4, correctif product_impressions, batterie de tests, mise en ligne de l'API) s'est prolongée jusqu'au 22 août — d'où la date de diffusion du présent dossier. Le détail figure au chapitre 17.

11.2 Diagramme de Gantt (11 → 22 août 2026)

DIAGRAMME DE GANTT — PROJET DATA-PRICE

Plateforme Data-Driven Pricing & Recommendation · Cheffe de projet : Marie Sow · Avancement 100 % — échéance le 20/08, finalisation technique (v4) le 22/08




Figure 2 — Diagramme de Gantt : chaque ligne = une tâche du WBS et son responsable ; colonnes = jours (11 au 22 août). Le repère rouge marque l'échéance académique du 20/08 ; la finalisation technique (v4) court jusqu'au 22/08.

Le diagramme de Gantt est la traduction visuelle du planning. Chaque ligne correspond à une tâche issue du WBS et à son responsable ; les colonnes représentent les jours. Une barre indique la période pendant laquelle la tâche est planifiée. Des barres superposées verticalement signalent des tâches menées en parallèle (par exemple, la data science et la BI progressent en même temps). Le chemin critique passe par Données prêtes (J1) → Modèles (J2) → API / Dashboard (J3) → Livraison.

12. Suivi de l'avancement (Trello)

L'avancement au quotidien a été piloté sur un tableau Trello en Kanban (colonnes À faire / En cours / Terminé), dont chaque carte porte l'étiquette de son lot WBS. Le tableau était connecté à Slack pour la remontée automatique. À la clôture du projet, l'ensemble des cartes est passé en colonne « Terminé ».

Carte (tâche)	Lot WBS	Resp.	État
Cadrage, kickoff & mise en place outils	1	Marie	Terminé
Architecture technique & schéma de données	2	Mozart	Terminé
Jeu de données synthétique + scripts ingestion	2	Mozart	Terminé
Data lake & entrepôt (schéma étoile)	3	Mozart	Terminé
Profiling, règles qualité & catalogage	4	Mozart	Terminé
Prévision demande (LightGBM/Croston)	5	Younes	Terminé
Simulation de remise (baseline médiane)	5	Younes	Terminé
Recommandation (CatBoostRanker, conversion)	5	Younes	Terminé
KPI & dashboard décisionnel	7	Siby	Terminé
API FastAPI + dockerisation (MLOps)	6	Younes	Terminé
Tests (pytest), intégration & évaluation	6	Équipe	Terminé
Business case, ROI & rapport stratégique	7	Siby+Marie	Terminé
Répétition générale	1	Équipe	Terminé
Livraison & dossier final	1	Équipe	Terminé

PARTIE III

Réalisation de la solution data

Le « ce qu'on a fait et comment » : architecture, données, qualité, modèles, industrialisation et BI

13. Vue d'ensemble de la solution

La solution s'organise en deux couches. La première est un data lake structuré en zones successives — Raw, Bronze, Silver puis Gold — où la donnée est progressivement nettoyée et enrichie sans jamais être modifiée en place, ce qui permet de rejouer le pipeline à tout moment. La seconde est un entrepôt de données alimenté par la zone Gold, hébergé sur Supabase (PostgreSQL), qui expose des données directement exploitables par les modèles et par la BI.

Cette architecture sert quatre usages : les trois cas d'usage data science (prévision, simulation de remise, recommandation) et le dashboard décisionnel des product managers. Elle est décrite en détail dans le livrable d'architecture de l'équipe data engineering, dont le contenu est repris et actualisé ci-dessous ainsi qu'en Annexe A.




Figure — Architecture de bout en bout : des sources au data lake (Raw → Gold), à l'entrepôt en étoile, aux modèles, puis à l'API et au dashboard.

14. Lots 2 & 3 — Architecture & données

14.1 Le data lake : zones et responsabilités

Chaque zone correspond à un niveau de confiance et de transformation croissant. Aucune donnée n'est modifiée en place : chaque étape écrit dans la zone suivante, ce qui permet de rejouer le pipeline à tout moment depuis la zone Raw. Le partitionnement des grandes tables (ventes, événements web) par année / mois / jour limite les volumes scannés et facilite les reprises incrémentales dans l'orchestrateur.

Zone	Format	Contenu
------	--------	---------

Raw	CSV / JSON	Copie brute et immuable des sources, telle que reçue. Sert d'archive et permet le rejeu en cas d'erreur en aval.
Bronze	Parquet	Données typées, dédoublées, dates normalisées, partitionnées par date d'ingestion. Aucune logique métier appliquée.
Silver	Parquet	Règles de qualité (great_expectations) appliquées : doublons et clés orphelines isolés, catégories normalisées, valeurs manquantes traitées.
Gold	Parquet	Données agrégées ou dénormalisées, prêtes à l'emploi : features pour les modèles ML, tables sources du data warehouse.

La zone Gold est la seule que les équipes data science et BI consomment directement — les zones Raw, Bronze et Silver restent internes au pipeline d'ingestion.

14.2 Le data warehouse : schéma en étoile

Le modèle retenu est un schéma en étoile. Dans sa version consolidée, il compte cinq tables de faits à des grains différents (ventes, événements web, stock, expérimentation prix, exposition recommandation) et quatre dimensions partagées (produit, client, date, promotion).

Table de faits	Grain (une ligne = ...)	Rôle principal
fact_ventes	un produit vendu dans une commande	Cœur transactionnel : cible de la prévision, base de la simulation de remise et de la marge.
fact_evenements_web	un événement de navigation (view / add_to_cart / purchase)	Funnel de navigation : signaux implicites pour la recommandation.
fact_stock	le niveau de stock d'un produit en fin de journée	Lève l'ambiguïté d'une vente à zéro (absence de demande vs rupture de stock).
fact_experimentation_prix	une décision de prix évaluée pour un produit, une semaine donnée	Expérience randomisée synthétique : mesure de l'effet causal des remises.
fact_exposition_reco	une recommandation affichée à un visiteur, dans une liste	Distingue un produit ignoré d'un produit jamais montré.

Les dimensions produit et client sont historisées (SCD Type 2, colonnes valid_from / valid_to / is_current) : lorsqu'un prix ou un segment change, une nouvelle ligne est insérée plutôt que d'écraser l'historique — une propriété indispensable à la prévision et à la simulation de remise, qui doivent reconstituer le prix ou le segment en vigueur à une date donnée. La dimension date est un calendrier pré-calculé (année, mois, jour de semaine, week-end) ; la dimension promotion reste simple, une promotion étant une entité à durée de vie courte et non modifiée après création. Le dictionnaire complet des colonnes figure en Annexe A.

LE SCHÉMA EN ÉTOILE — 5 TABLES DE FAITS · 4 DIMENSIONS




Figure — Le schéma en étoile : cinq tables de faits au centre, quatre dimensions partagées (produit et client en SCD Type 2).

14.3 Évolution du schéma : de la v1 à la v4

Le schéma a évolué en plusieurs versions, chacune sous le contrôle d'un audit indépendant (le détail des versions figure au chapitre 17). En résumé :

- **Correction** — la table `fact_stock`, absente de la toute première version, a été rajoutée — un oubli de conception assumé et corrigé. Sans elle, une vente à zéro un jour donné reste ambiguë.
- **Enrichissement (v2 du modèle, 19/08)** — deux journaux ont été ajoutés — `fact_experimentation_prix` et `fact_exposition_reco` — en réponse au retour de la data science du 18 août.
- **Durcissement (v3, 20/08)** — audit de ces journaux : correction des fuites de cible et ajout d'un lineage complet (script, seed, empreinte SHA-256) ; statut requalifié « expérience randomisée synthétique ».
- **Finalisation (v4, 21/08)** — contre-audit et corrections techniques finales (construction sans information future, analyse au grain produit) ; statut `synthetic_academic_experiment`, reproductibilité prouvée.

Traçabilité de la démarche. Cette évolution illustre le fonctionnement itératif de l'équipe : chaque besoin ou anomalie remonté par la data science a donné lieu à une révision documentée et versionnée, plutôt qu'à un contournement silencieux. Le détail complet est consigné dans les journaux de version (README v2 → v4) et synthétisé au chapitre 17.

14.4 Choix techniques et volumétrie

Composant	Choix	Justification
Stockage lake	S3 / MinIO, format Parquet	Standard data lake, orienté colonnes, compatible Spark et pandas.
Data warehouse	PostgreSQL (Supabase)	Suffisant pour les volumes du projet ; déploiement managé rapide.
Orchestration	Airflow ou Prefect	Un DAG par zone

		(Raw→Bronze→Silver→Gold), dépendances explicites, reprise sur échec.
Qualité de données	great_expectations	Règles automatisées sur le passage Bronze→Silver.
Transformation SQL	dbt (optionnel)	Matérialiser Silver→Gold→étoile de façon versionnée et testable.

Ordres de grandeur de la volumétrie (jeu de données synthétique) : environ 84 000 lignes de ventes, 657 000 événements web et 118 000 lignes de stock quotidien pour les tables cœur ; les deux journaux d'expérimentation et d'exposition, dans leur version 4 consolidée, comptent respectivement ~11 800 décisions de simulation de remise et ~221 000 expositions de recommandation (leurs volumes ont varié d'une version à l'autre au gré des corrections — voir chapitre 17). Ces volumes restent à la portée d'un PostgreSQL managé.

État de chargement : la couche Gold est en ligne sur Supabase — table des ventes, événements web, dimensions, ainsi que la table de stock et les deux journaux d'expérimentation et d'exposition, qui ont été générés puis chargés dans l'entrepôt.

15. Lot 4 — Qualité des données & catalogage

La fiabilité des analyses repose sur la qualité des données. Le jeu de données synthétique intègre volontairement des anomalies réalistes — doublons, valeurs manquantes, clés étrangères orphelines, quantités négatives, casse incohérente, horodatages désordonnés — afin de démontrer la capacité du pipeline à les détecter et à les traiter. Ces anomalies sont isolées au passage Bronze → Silver.

Le contrôle de qualité s'appuie sur great_expectations : des règles formelles (complétude, unicité, cohérence des clés, plages de valeurs, fraîcheur) remplacent progressivement les vérifications codées à la main. Un catalogage minimal (glossaire des tables et des colonnes) accompagne le jeu de données pour en faciliter la reprise. Les règles great_expectations ont été exécutées sur le pipeline : les anomalies injectées sont détectées et isolées au passage Bronze → Silver, garantissant la fiabilité des données servant aux modèles et à la BI.

16. Lot 5 — Modélisation data science

Trois domaines structurent la modélisation : la prévision de la demande, la simulation des conséquences d'une remise et la recommandation. Tout est réalisé sur données synthétiques (statut synthetic_academic_experiment) : aucun résultat ne constitue une performance commerciale réelle et aucun effet causal n'est estimé. Chaque modèle est comparé à une baseline obligatoire ; seuls ceux qui la battent de façon démontrée sont retenus. Les résultats ci-dessous sont les métriques finales du rapport de modélisation.

16.1 Prévision de la demande

Objectif : estimer le nombre d'unités par produit sur 30 jours. Deux modèles sont retenus : LightGBM_direct_per_horizon pour la planification cumulée à 30 jours et CrostonOptimized pour la prévision quotidienne. Le protocole repose sur six fenêtres de test hors échantillon ; le modèle de planification bat la référence (LightGBM_Tweedie) sur les six fenêtres.

Métrique (cumul 30 jours)	Valeur
WAPE30 macro	0,25831
WAPE30 micro	0,25743

Biais macro	-0,02589 (sous-estimation $\approx$ 2,6 %, faible et acceptable)
-------------	--

Lecture correcte. La demande est fortement intermittente (la moitié des produits ont une médiane hebdomadaire de ventes nulle). L'erreur relative quotidienne dépasse donc mécaniquement 1 ; c'est pourquoi la décision porte sur le cumul à 30 jours, où l'agrégation lisse l'intermittence. Une WAPE30 de 0,258 est un bon résultat dans ce contexte, mais ne se traduit pas en « pourcentage de bonnes prévisions ».

16.2 Tarification — simulation des conséquences d'une remise

Objectif : simuler les conséquences comptables (volume, chiffre d'affaires, marge) d'une remise. Statut : simulation uniquement — aucun effet causal n'est estimé et aucun prix optimal n'est calculé automatiquement. Le modèle retenu est `baseline_mediane_produit` (médiane historique des ventes hebdomadaires par produit) ; aucun modèle d'apprentissage n'a battu cette baseline.

Cible simulée (fenêtre 7 j)	WAPE macro	Biais
Unités vendues	0,1342	+0,0054
Chiffre d'affaires (XOF)	0,1299	+0,0020
Marge (XOF)	0,1305	+0,0004


Pourquoi aucune causalité n'est revendiquée. Le niveau de remise, la classe ABC et le statut de démarrage à froid sont fixes par produit sur toute l'expérience : la remise n'est jamais observée à deux niveaux différents pour un même produit, elle est donc confondue avec l'identité du produit. Aucune affirmation du type « cette remise cause ce volume » n'est possible. Garde-fous vérifiés : sur les 11 799 décisions, zéro prix sous le coût et zéro marge sous le plancher.

16.3 Recommandation

Objectif : ordonner un ensemble de produits candidats (réordonnancement de listes de cinq). Un modèle est retenu par cible, avec `popularite_globale_v1` comme repli général. Les gains sont mesurés en NDCG@10 — le seul critère réellement discriminant ici, les métriques de rappel étant invariantes au réordonnancement sur des listes fermées de cinq candidats.

Cible	Modèle retenu	Gain NDCG@10	Statut
Achat (<code>purchased_after</code>)	CatBoostRanker	+8,57 %	Validé
Ajout au panier (<code>added_to_cart_after</code>)	pointwise_conversion	+7,70 %	Validé
Consultation (<code>viewed_after_impression</code>)	CatBoostRanker	+5,57 %	Exploratoire (non servi)

L'ENTONNOIR DE CONVERSION — OÙ AGISSENT LES MODÈLES



La recommandation ordonne les produits exposés ; la simulation projette l'impact d'une remise

Figure — L'entonnoir de conversion : la recommandation ordonne les produits exposés au visiteur ; la simulation de remise en projette l'impact comptable.

Précisions honnêtes : gains mesurés hors ligne sur données synthétiques ; le catalogue de recommandation couvre 208 produits sur 300 (92 n'ont jamais été exposés) ; le service réordonne un ensemble de candidats déjà sélectionné, il ne les choisit pas. La cible de consultation, d'abord promue, a été reclassée en exploratoire par une validation indépendante (p-value brute de 0,088, non significative) — elle reste consultable mais n'est servie par défaut par aucun point d'entrée.

16.4 Bilan des modèles retenus

Composant	Modèle	Statut
Prévision 30 jours	LightGBM_direct_per_horizon	Validé, référence
Prévision quotidienne	CrostonOptimized	Validé, référence
Tarification (3 cibles)	baseline_mediane_produit	Validé, simulation uniquement
Recommandation achat	CatBoostRanker	Validé académiquement
Recommandation panier	pointwise_conversion	Validé académiquement
Recommandation consultation	CatBoostRanker	Exploratoire, non servi
Repli général	popularite_globale_v1	Validé, secours

Point d'attention (stock). La demande observée est en partie masquée par les ruptures de stock (un produit indisponible affiche zéro vente sans que la demande ait été nulle). La table de stock quotidien étant chargée dans l'entrepôt, elle est prise en compte dans l'interprétation de la prévision.

17. Démarche itérative & livraisons par version

Le moteur du projet a été une boucle d'amélioration continue entre l'équipe data science (qui audite) et l'équipe data engineering (qui produit et corrige). Chaque livraison a été audité en lecture seule, puis renvoyée avec une

liste précise d'anomalies ; la correction a donné lieu à une nouvelle version, à son tour contre-auditée. Ce chapitre retrace ce cycle et les livraisons par version.

UNE DÉMARCHE ITÉRATIVE — LA BOUCLE D'AMÉLIORATION CONTINUE




Figure — La boucle d'amélioration continue (audit → correction → contre-audit) et la progression du modèle de données de la v1 à la v4.

17.1 Le cycle audit → correction → contre-audit

- **14/08** — l'équipe data science fige et documente les premiers modèles (prévision, simulation de remise, recommandation), sur des données auditées avant modélisation.
- **15-16/08** — elle demande des enrichissements (identifiant de commande, attributs de session) ; l'équipe data engineering précise les règles de session et livre. Un audit SQL relève 4 anomalies (promotions mal ciblées, stock non réconciliable...), corrigées puis confirmées. Marie dépose le cahier des charges v2 et la fiche KPI.
- **17/08** — contre-vérification indépendante : horodatages UTC, découpage des sessions et ordre du funnel conformes.
- **18/08** — la data science partage la synthèse des trois volets, déploie la documentation de l'API en ligne, puis demande les données d'expérimentation et d'exposition manquantes.
- **19/08** — livraison des deux journaux fact_experimentation_prix et fact_exposition_reco (première version).
- **20/08** — audit exhaustif : des fuites de cible sont identifiées (classe_abc, product_impressions, stock_at_decision ; 97,97 % des impressions hors des bornes réelles de session). Reconstruction en v3, statut requalifié « expérience randomisée synthétique », avec lineage complet (script, seed, empreinte SHA-256).
- **21/08** — contre-audit de la v3, puis livraison d'une v4 corrigeant les dernières anomalies techniques et statuée synthetic_academic_experiment.

17.2 Livraisons par version

Livable (flux)	Trajectoire de versions	Amélioration clé apportée
Cahier des charges (Marie)	v1 (11/08) → v2 (16/08)	Intègre la mise à jour d'architecture, la fiche KPI et les enrichissements du jeu

		de données.
Architecture & schéma de données (Mozart)	v0 (pré-étoile) → v1 (schéma en étoile + ETL, 13/08)	Passage à un schéma en étoile documenté et à un pipeline reproductible chargé sur Supabase.
Enrichissements du jeu de données (Mozart)	15-16/08	Ajout de l'identifiant de commande et des attributs de session ; correction de 4 anomalies (promotions, stock...).
Modèles prévision / simulation / reco (Younes)	Résultats v1 (14/08) → V4 validée + API en ligne	Métriques finales (WAPE30, NDCG@10) ; API V4 déployée et testée (147 tests).
Journaux expérimentation & exposition (Mozart)	v2 (19/08) → v3 (20/08) → v4 (21/08)	Correction des fuites de cible, lineage/seed/SHA-256, analyse au grain produit.

17.3 Le durcissement des deux journaux (v1 → v4)

Les tables d'expérimentation de prix et d'exposition de recommandation illustrent le mieux la démarche. Ajoutées le 19 août (première version des journaux, dite v2 du modèle de données) pour répondre à un besoin de la data science, elles ont ensuite été durcies en deux itérations successives, sous le contrôle d'audits indépendants :

- **v3 (20/08)** — les fuites de cible sur classe_abc, stock_at_decision et les résultats simulés sont éliminées (classe_abc calculée sur un warm-up strictement antérieur, stock de clôture J-1, outcomes simulés comme fonction causale de la remise appliquée). Assignment persistante par produit, promotions historiques neutralisées, randomisation par blocs équilibrée, lineage complet. La variable product_impressions, elle, restera en défaut jusqu'à une correction ultérieure (voir §17.5).
- **v4 (21/08)** — chaque liste de recommandation n'est construite qu'avec l'information disponible à l'instant de l'impression (0 produit « futur »), deux politiques réellement distinctes (popularité vs affinité catégorie), warm-up corrigé à 90 jours, démarrage à froid explicite, ajout d'un indicateur de marge, et surtout analyse de significativité au grain produit plutôt qu'au grain produit-semaine. Reproductibilité prouvée : mêmes empreintes SHA-256 à la ré-exécution.

Un résultat honnête. Au grain produit ($n \approx 300$) et après correction de Holm, aucun effet des remises n'est statistiquement significatif (p ajustées de 0,53 à 1,0). C'est le résultat attendu et correct : l'effet qui semblait significatif en v3 provenait du traitement, à tort, de ~13 000 lignes produit-semaine comme des observations indépendantes. Sur des données synthétiques, l'objectif n'était pas de « prouver » un gain commercial mais de démontrer un pipeline causal rigoureux — capable, aussi, de conclure honnêtement à l'absence d'effet.

Nommer les choses justement. Conformément aux audits, ces tables ne sont jamais présentées comme une « vraie expérience » : leur statut est explicitement « expérience randomisée synthétique » / synthetic_academic_experiment. De même, trois champs demandés (prix concurrents, budget de campagne, ventes perdues) restent volontairement exclus faute de source fiable — un choix assumé et tracé, plutôt que des colonnes vides.

17.4 Historique des versions des modèles (V1 → V4)

Côté data science, la modélisation a suivi la même logique de versions successives. Les métriques d'une version ne sont jamais comparables à celles d'une autre (jeux de données, périmètres et protocoles différents).

Version	Objectif	Résultat & décision
V1 — bases de référence	Établir des baselines et mesurer la difficulté réelle.	Demande très intermittente, erreurs relatives élevées. Décision : garder les baselines comme références obligatoires — aucun modèle accepté s'il ne les bat pas.
V2 — consolidation	Fiabiliser les résultats et corriger les défauts.	Prévision validée et promue. Un audit détecte deux fuites de cible (tarification et recommandation) : résultats concernés invalidés (jamais supprimés), corrigés puis republiés.
V3 — enrichissement	Intégrer une livraison de données enrichie.	Anomalies suffisantes pour ne rien fonder dessus. Version mise en attente : aucun modèle V3 n'est utilisé.
V4 — mise en service	Entraîner tarification et recommandation avec un protocole anti-fuite strict.	Aucun modèle de tarification ne bat la baseline ; trois modèles de recommandation franchissent le seuil, dont un reclassé en exploratoire après validation indépendante.

17.5 Les quatre audits de validité

Le projet a fait l'objet de quatre audits distincts. Ils sont la raison pour laquelle plusieurs résultats intermédiaires ont été écartés, et la garantie de fond des conclusions retenues.

Audit	Constat principal	Traitement
1 · Fuites de cible (V2)	Une variable de tarification était une composante directe de la cible ; un score de recommandation accédait à la catégorie du produit masqué.	Résultats marqués invalidés (jamais supprimés) ; noyau de scoring refondu, structurellement incapable de voir la cible.
2 · Livraison V3	55 % des listes contenaient un produit futur ; sélection des sessions corrélée à l'achat ; traitement sans effet réel ; incohérences de tarification.	Livraison jugée non valide pour la modélisation ; V3 mise en attente.
3 · Audit automatisé V4 (20 contrôles)	17 réussites, 2 avertissements, 1 échec : product_impressions valait le total de la période, pas le cumul antérieur à la décision (cause : un mélange d'unité microseconde/nanoseconde dans le calcul).	Corrigé à la source le 22/08 ; les deux tables reconstruites et rechargées dans Supabase (nouvelle empreinte SHA-256), validées par un second calcul indépendant.
4 · Validation indépendante des gains reco	Métriques, bootstrap et correction de Holm entièrement réécrits : estimations reproduites à l'identique, mais la cible de consultation ressort à $p = 0,088$ (non significative).	Modèle de consultation reclassé de promu à exploratoire — seul cas du projet où une contre-expertise a renversé une décision.

Ce que cela démontre. Au-delà des résultats, cette discipline d'audit — jusqu'à faire vérifier un gain par un

chemin de code entièrement indépendant — est la meilleure garantie de sérieux du volet modélisation. Quatre garde-fous permanents (immutabilité de la prévision par empreintes SHA-256, intégrité des artefacts, contexte de construction, absence de fuite) s'exécutent en outre à chaque validation.

18. Lot 6 — Industrialisation (API & MLOps)

L'industrialisation — API, console web, conteneurisation Docker, tests et déploiement — a été réalisée par le Data Scientist (Younes Hachami). Le Data Engineer (Mozart Codjo) est intervenu sur l'enrichissement des données, en amont.

18.1 API & console web

Une API (FastAPI) et une console web, toutes deux en français, exposent les modèles. Les principaux points d'entrée sont : `/forecast` (prévision 30 jours), `/recommendations` et `/recommendations/cart` (recommandation d'achat et d'ajout au panier), `/pricing/simulation` (simulation de remise), ainsi que `/health`, `/metrics`, `/metadata` et `/docs` (documentation interactive). La console propose quatre pages : recommandation, simulation de remise, prévision 30 jours, et scores & validation — sans cadriciel ni ressource distante, testée sur poste de bureau et sur mobile.

Le contrat de réponse distingue explicitement le modèle demandé, le modèle réellement utilisé et leurs statuts, afin qu'un repli ne soit jamais confondu avec un service nominal. Un échec de prédiction produit une erreur explicite, jamais un zéro (un zéro renvoyé est donc toujours une valeur réellement prédite). Les routes de prévision servent un instantané de backtest hors échantillon — ce n'est pas une prévision du futur.

18.2 Tests, reproductibilité & MLOps

La reproductibilité repose sur une graine aléatoire fixée (42) dans tous les modules, des modèles sérialisés et versionnés, un manifeste d'empreintes SHA-256 par répertoire validé automatiquement, un registre de statut consolidé (source unique de vérité) et une surveillance via `/health` et `/metrics`. Une batterie unique de tests (dix étapes, de l'immutabilité de la prévision aux tests d'intégration avec démarrage d'un serveur réel) s'exécute d'un seul appel.

Résultat des tests. 147 tests réussis, 0 ignoré, 0 échec. Un garde-fou d'immutabilité vérifie que les artefacts de prévision, déjà validés, restent identiques (empreintes SHA-256) à chaque exécution.

18.3 Déploiement


Le service V4 est déployé comme service distinct du service V2 (image Docker dédiée `Dockerfile.api_v4`), le V2 restant en ligne et inchangé. La console et l'API V4 sont accessibles en ligne (`examen-data-driven-v4.onrender.com`) ; le code, les modèles, les tests et la documentation sont versionnés sur le dépôt GitHub du projet.

Incident de déploiement (résolu). Sans désignation explicite de l'image V4, la plateforme sélectionnait par défaut l'image à la racine et déployait la V2 en croyant déployer la V4. L'incident a été détecté et corrigé en pointant explicitement `Dockerfile.api_v4` ; le critère de vérification est structurel (présence des routes V4, absence des routes V2). Il figure au registre des risques (R9).

19. Lot 7 — BI, KPI & dashboard décisionnel

La restitution s'adresse aux product managers via le tableau de bord décisionnel « Teranga BI » (BI Analyst), branché sur le schéma en étoile. L'ensemble des indicateurs est alimenté par l'entrepôt (et par les sorties des modèles pour ceux qui en dépendent). Le tableau de bord couvre les six familles de KPI ci-dessous.

Famille de KPI	Exemples d'indicateurs	Source
Marge, prix & ventes	Taux de marge brute, CA net, panier moyen, impact simulé d'une remise	Entrepôt (impact via simulation)
Stock & demande	Rotation, couverture de stock, taux de rupture, précision de la prévision	Entrepôt (précision via forecast)
Parcours d'achat en ligne	Taux de conversion, taux d'abandon de panier	Entrepôt
Recommandation & ventes croisées	Part des paniers multi-produits, qualité des recommandations	Entrepôt (qualité via modèle reco)
Clients & fidélisation	Valeur vie client (CLTV), répartition du CA par segment	Entrepôt
Valeur & qualité	Suivi de la valeur du projet, qualité des données	Business case + entrepôt



Maquette de structure du dashboard décisionnel (tuiles KPI, graphiques, segments) — les valeurs ne sont pas renseignées ; elles seront alimentées par la BI depuis l'entrepôt.

19.1 Filtres et sécurité par profil (RLS) — politique cible

Le tableau de bord est interactif : des filtres permettent de croiser les indicateurs par période, catégorie de produits, segment de clientèle et région. La politique de sécurité au niveau des lignes (Row-Level Security) ci-dessous définit, pour chaque profil, le périmètre de données visible. Il s'agit de la politique cible à mettre en œuvre dans Supabase ; sa création effective côté base relève de la phase de mise en production et reste à confirmer.

Profil utilisateur	Portée visible (RLS)	Filtres principaux
Direction / Product Owner	Toutes les données, tous périmètres	Période, catégorie, segment, région
Manager régional	Uniquement sa région	Période, catégorie, segment
Analyste catégorie	Uniquement ses catégories de produits	Période, segment, région
Analyste BI	Lecture complète (analyse), sans données personnelles	Tous filtres

PARTIE IV

Valeur, risques & conformité

Business case, ROI, gestion des risques, RGPD et protection des données

20. Business case & retour sur investissement

Le business case met en regard les coûts de mise en œuvre et les gains attendus. Dans le cadre académique, les montants restent illustratifs — les données sont synthétiques et le déploiement est simulé — mais la logique de création de valeur est bien réelle.

Les coûts se répartissent entre le développement et la modélisation (temps de l'équipe), l'infrastructure (stockage du data lake, entrepôt) et l'exploitation (surveillance des modèles). Les leviers de valeur attendus sont : une meilleure disponibilité produit grâce à la prévision, un pilotage plus éclairé des remises grâce à la simulation, et un revenu incrémental de cross-sell / up-sell grâce à la recommandation.

20.1 KPI métier — hypothèses ex-ante

Les cibles ci-dessous sont des hypothèses métier fixées au cadrage, à titre de référentiel. Elles ne sont pas des résultats : sur données synthétiques, aucun effet causal n'est démontré. Les métriques réellement mesurées par les modèles figurent au chapitre 16.

Objectif métier	KPI de suivi	Cible (hypothèse ex-ante)
Préserver la marge	Taux de marge brute moyen	+3 à +8 %
Réduire ruptures & surstocks	Taux de rupture / de surstock	-20 à -30 %
Augmenter les ventes croisées	Conversion cross-sell / up-sell	+5 à +10 %
Fidéliser les clients	CLTV (valeur vie client)	+5 à +12 %
Améliorer la conversion	Taux de conversion du funnel web	+2 à +5 pts

Résultats réellement mesurés (chapitre 16). Côté recommandation, les gains hors ligne sont significatifs : +8,57 % de NDCG@10 sur l'achat et +7,70 % sur l'ajout au panier (validés). Côté prévision, une WAPE30 de 0,258 avec un biais quasi nul. Côté remise, la simulation ne démontre aucun effet causal (aucun modèle ne bat la baseline, et la remise est confondue avec l'identité produit). Les montants en FCFA restent illustratifs, le déploiement étant académique.

21. Gestion des risques

Neuf risques ont été identifiés (huit au cadrage, un en cours de projet), cotés en probabilité (P) et impact (I), et assortis d'une réponse. Le registre est suivi tout au long du projet.

P / I : F = Faible · M = Moyen · É = Élevé.

ID	Risque	P	I	Criticité	Réponse /
----	--------	---	---	-----------	-----------

					mitigation
R1	Qualité des données insuffisante (synthétique peu réaliste)	M	É	Élevée	Règles great_expectations dès l'ingestion ; revue du générateur ; jalon J1 bloquant.
R2	Délai très court (10 jours) — sous-estimation des tâches	É	É	Élevée	Périmètre MVP priorisé ; parallélisation ; bonus reportés ; jalons quotidiens.
R3	Absentéisme / disponibilité inégale	M	É	Élevée	Binômage, doc partagée, RACI clair, back-up sur tâches critiques.
R4	Rôle MLOps non attribué initialement	M	M	Moyenne	Rôle porté par le Data Scientist (API, Docker, tests, déploiement).
R5	Modèles peu performants vs baseline	M	M	Moyenne	Baselines simples d'abord ; itérations CRISP-DM ; critères réalistes.
R6	Intégration API / Docker tardive	M	É	Élevée	API mockée tôt ; conteneurisation dès J2 ; tests pytest continus.
R7	Non-conformité RGPD / protection des données	F	É	Moyenne	Données synthétiques ; plan RGPD ; pseudonymisation des identifiants.
R8	Dérive de périmètre (scope creep)	M	M	Moyenne	Gel du périmètre ; évolution arbitrée par la cheffe de projet.
R9	Incident de déploiement (mauvaise image Docker mise en ligne)	M	M	Moyenne	Désignation explicite de l'image V4 ; vérification structurelle (routes V4 présentes, V2 absentes) — survenu et corrigé.




Figure — Matrice des risques (probabilité × impact) : positionnement des 8 risques du registre ; R2 (délai) au plus haut.

22. Conformité RGPD & protection des données

22.1 Principe directeur

Le projet s'exerce sur un jeu de données synthétique : aucune donnée personnelle réelle n'est collectée ni traitée, ce qui réduit fortement l'exposition au RGPD. Les mesures ci-dessous sont néanmoins définies pour démontrer la conformité « by design » et préparer un passage en production.

22.2 Mesures RGPD

- **Minimisation** : ne générer / traiter que les attributs strictement utiles au cas d'usage.
- **Pseudonymisation** : identifiants clients pseudonymisés (aucune ré-identification en synthétique).
- **Base légale (en prod)** : intérêt légitime / consentement pour les données comportementales et la personnalisation.
- **Registre des traitements** : finalités, catégories de données, durées de conservation, destinataires.
- **Droits des personnes (en prod)** : accès, rectification, effacement, opposition au profilage.
- **Sécurité** : contrôle d'accès au dépôt, secrets hors code, chiffrement des flux sensibles (en prod).
- **Conservation** : durées limitées et purge planifiée des données.
- **DPIA léger** : analyse d'impact simplifiée pour le profilage et la personnalisation.

PARTIE V

Bilan & clôture

État d'avancement, enseignements, limites, perspectives et alignement sur l'évaluation

23. État d'avancement à la livraison

À la livraison, l'ensemble des jalons du projet a été franchi. Le cadrage (lot 1), l'architecture et les données (lots 2-3), les contrôles de qualité (lot 4), la modélisation data science (lot 5), l'industrialisation (lot 6) et la restitution BI (lot 7) sont réalisés. Toutes les cartes du tableau de suivi Trello sont passées en colonne « Terminé » (chapitre 12) et le diagramme de Gantt affiche un avancement global de 100 %. Le sprint s'est clôturé à l'échéance du 20 août ; la finalisation technique (audit V4, correctif, 147 tests, mise en ligne de l'API) s'est achevée le 22 août, date du dossier consolidé. Le chemin critique — données, puis modèles, puis API / dashboard, puis livraison — a été tenu.

24. Enseignements & retour d'expérience

Quatre enseignements ressortent de la conduite du projet, du point de vue de la gestion de projet :

- **Cohérence** — la cohérence documentaire est un multiplicateur d'efficacité. Aligner le WBS, le Gantt, le Trello et le présent dossier sur les sept mêmes lots a supprimé les ambiguïtés de périmètre et facilité le suivi.
- **Itération** — l'itération vaut mieux que la perfection au premier jet. Le modèle de données a gagné en qualité précisément parce que chaque audit a été accueilli et intégré (quatre versions successives, v1 → v4, correction des fuites de cible, lineage reproductible) plutôt que figé. La boucle audit → correction → contre-audit (chapitre 17) est le principal atout méthodologique du projet.
- **Transparence** — l'honnêteté intellectuelle renforce la crédibilité. Nommer explicitement les limites (données synthétiques, déploiement simulé, champs volontairement exclus, cibles non garanties) vaut mieux que de les masquer.
- **Coordination** — la parallélisation et le binômage ont permis de tenir un délai très court, au prix d'une coordination quotidienne rigoureuse (Slack, Trello, RACI).

25. Limites assumées & perspectives (v2)

Le projet est livré complet dans son périmètre MVP. Les limites ci-dessous, inhérentes au cadre académique, sont assumées et documentées ; plusieurs perspectives d'évolution sont identifiées pour une version 2.

25.1 Limites des données

- Données entièrement synthétiques (statut `synthetic_academic_experiment`) : aucune conclusion ne se transpose à une activité réelle sans nouvelle validation.
- Demande fortement intermittente : la moitié des produits ont une médiane hebdomadaire de ventes nulle, ce qui gonfle mécaniquement l'erreur relative quotidienne.
- Aucune donnée concurrentielle, et aucune élasticité prix observable indépendamment de l'identité du produit — d'où l'impossibilité d'une conclusion causale sur les remises.

- Aucune mesure de la demande perdue : les ruptures de stock ne sont pas distinguées d'une absence de demande.

25.2 Limites du service

- Aucune authentification ni limitation de débit sur l'API.
- Instantanés (modèles, catalogue) figés à la fin de la fenêtre d'entraînement, jamais rafraîchis automatiquement.
- Aucune surveillance de dérive (data drift / concept drift) ni test de charge.

25.3 Perspectives (version 2)

- Mise en production réelle : bascule de l'entrepôt et de l'API sur l'infrastructure cible, avec monitoring des modèles (data drift, concept drift) et réentraînement périodique.
- Rejouer le protocole sur des données réelles, avec une variation de remise indépendante de l'identité produit — seule condition permettant une conclusion causale sur les remises.
- Conduire un test A/B en ligne pour mesurer les gains de recommandation, non transposables depuis le hors-ligne ; étendre le catalogue de recommandation au-delà des 208 produits actuels.
- Pistes techniques : approches par embeddings et recherche de voisins (FAISS), non retenues dans le périmètre réalisé ; explicabilité des modèles (XAI) ; modélisation du churn et de la CLTV.

26. Alignement sur la grille d'évaluation

Le tableau ci-dessous rattache chaque critère d'évaluation aux parties du dossier qui le couvrent.

Critère	Pondération	Où c'est traité dans ce dossier
Gouvernance & stratégie	15 %	Parties I & II (cadrage, RACI, gouvernance), Partie IV (business case, RGPD).
Architecture & qualité pipeline	20 %	Partie III, ch. 13-15 (architecture, données, qualité) ; Annexe A.
Modèles & validation	25 %	Ch. 16 (modèles & métriques finales), ch. 17 (versions modèles, 4 audits, contre-expertise) ; Annexe B.
Intégration & déploiement	15 %	Partie III, ch. 18 (API, MLOps, CI/CD).
Business case & KPIs	15 %	Partie III, ch. 19 & Partie IV, ch. 20 (dashboard, KPI, ROI).
Présentation & documentation	10 %	L'ensemble du présent dossier autoportant + dépôt de code.

27. Conclusion

La plateforme DATA-PRICE répond à un besoin métier clairement identifié — améliorer la marge, la disponibilité des produits et la fidélisation — par une exploitation méthodique des données. À la livraison, l'architecture est en place, le jeu de données est disponible et documenté, les contrôles de qualité sont opérationnels, les trois

modèles ont été entraînés et évalués sur la couche Gold de l'entrepôt, l'API et le dashboard décisionnel sont réalisés, et le business case est consolidé.

Au-delà des livrables techniques, le projet démontre une conduite structurée : un cadrage rigoureux, une organisation lisible en sept lots, une gouvernance outillée et une capacité à faire évoluer la solution au fil des retours. Les limites sont assumées et converties en feuille de route (version 2). Ce dossier autoportant constitue la restitution complète du projet : il retrace ce qui a été fait, comment cela a été fait, et comment l'équipe s'est organisée pour y parvenir.

Document consolidé par Marie Sow, Cheffe de projet — Projet DATA-PRICE, 22 août 2026.

ANNEXES

Annexes techniques & de référence

Dictionnaire de données, guide de modélisation, registres détaillés et glossaire

Annexe A — Dictionnaire de données (schéma en étoile)

Détail des colonnes des cinq tables de faits et des quatre dimensions du schéma consolidé. PK = clé primaire, FK = clé étrangère. Toutes les jointures se font sur les clés de substitution (produit_key, client_key, date_key, promo_key), jamais sur les identifiants métier.

A.1 — fact_ventes · grain : un produit vendu dans une commande

Colonne	Type	Description
vente_id	string (PK)	Identifiant unique de la ligne de vente.
produit_key	string (FK)	Référence vers dim_produit (clé de substitution).
client_key	string (FK)	Référence vers dim_client.
date_key	string (FK)	Référence vers dim_date.
promo_key	string (FK, nullable)	Référence vers dim_promotion si une remise a été appliquée.
quantite	int	Quantité vendue.
montant_net_xof	float	Montant réellement payé, remise déjà appliquée.

A.2 — fact_evenements_web · grain : un événement de navigation

Colonne	Type	Description
event_id	string (PK)	Identifiant unique de l'événement.
produit_key	string (FK)	Référence vers dim_produit.
client_key	string (FK)	Référence vers dim_client.
date_key	string (FK)	Référence vers dim_date.
type_event	string	view, add_to_cart ou purchase.
appareil	string	mobile, desktop ou tablet.

A.3 — fact_stock · grain : niveau de stock d'un produit en fin de journée

Colonne	Type	Description
produit_key	string (FK)	Référence vers dim_produit.
date_key	string (FK)	Référence vers dim_date.

niveau_stock	int	Stock en fin de journée. Clé primaire composite (produit_key, date_key).
--------------	-----	--

A.4 — fact_experimentation_prix (v4) · grain : une décision de prix, un produit, une semaine

Colonne	Type	Description
decision_id	string (PK)	Identifiant unique de la décision.
experiment_id	string	Identifiant de la vague hebdomadaire d'expérimentation.
produit_key	string (FK)	Référence vers dim_produit.
decision_timestamp	timestampz	Horodatage de la décision, UTC.
treatment_group	string	controle_0pct / traitement_5/10/15pct — assignation persistante par produit, stratifiée (catégorie, classe ABC).
eligible_for_discount	boolean	Vrai si le prix respecte le plancher (prix $\geq$ coût) et la marge minimale (5 %).
discount_proposed / discount_applied	int / int	Remise du groupe assigné, et remise réellement appliquée (0 si le garde-fou bloque).
prix_applique_xof	numeric	Prix recalculé APRÈS le contrôle d'éligibilité, à partir de discount_applied (jamais discount_proposed).
propensity_score	numeric	Probabilité d'assignation au groupe (0,25 — 4 groupes équiprobables).
product_impressions	int	Cumul d'expositions reco strictement antérieur à decision_timestamp (corrigé le 22/08 — voir §17.5).
stock_at_decision	int	Stock de clôture J-1 (jamais le jour même de la décision).
categorie / classe_abc	string / string	Classe ABC calculée sur un warm-up de 90 jours strictement antérieur à l'expérience.
cold_start_warmup	boolean	Vrai si le produit n'a eu aucune vente pendant le warm-up (explicite, pas de plancher silencieux).
units_sold_window_7j / revenue_window_xof_7j / margin_window_xof_7j	int / numeric / numeric	Outcomes simulés comme fonction causale de discount_applied (élasticité documentée + bruit).
fenetre_observation_debut / fin	timestampz	Bornes explicites de la fenêtre d'observation de 7 jours.
statut_experience	string	Toujours 'synthetic_academic_experiment' — jamais présentée comme une vraie expérience.

A.5 — fact_exposition_reco (v4) · grain : une recommandation affichée à un visiteur (slate)

Colonne	Type	Description
recommendation_id	string (PK)	Identifiant unique de l'exposition.
slate_id	string	Identifiant partagé par tous les produits d'une

		même liste affichée (slate).
experiment_id / assignment_id	string / string	Identifiants de l'expérience et de l'assignation persistante du visiteur.
client_key / anonymous_id	string / string	Mutuellement exclusifs — visiteur connu ou anonyme.
session_id	string	Session réelle de fact_evenements_web (toujours dans les bornes de la session).
model_version	string	popularite_globale_v1 (contrôle) ou challenger_affinite_categorie_v1 (traitement) — jamais aléatoire.
model_score	numeric	Score calculé par le modèle, à partir d'informations strictement antérieures à l'impression.
produit_key	string (FK)	Produit recommandé, référence vers dim_produit.
rank	int	Position dans la liste, dérivée du tri par model_score (jamais aléatoire).
impression_timestamp	timestampz	Horodatage de l'affichage, UTC — dans les bornes réelles de la session.
viewed_after_impression / view_timestamp	boolean / timestampz	Remplace « clicked » (la source ne distingue pas clic et vue) — dérivé des vrais événements postérieurs à l'impression.
added_to_cart_after / purchased_after	boolean (+ timestamps)	Actions strictement postérieures à l'impression.
experiment_group	string	controle / traitement — assignation persistante par visiteur.
group_assignment_propensity / session_selection_probability / product_exposure_probability	numeric	Trois probabilités distinctes : assignation au groupe, sélection de la session, exposition du produit.

A.6 — Dimensions (produit, client, date, promotion)

Dimension	Colonnes clés	Particularité
dim_produit	produit_key (PK), product_id, categorie, marque, prix_base_xof, cout_xof, valid_from/valid_to/is_current	SCD Type 2 (historisation prix/version).
dim_client	client_key (PK), segment_fidelite, region, valid_from/valid_to/is_current	SCD Type 2 (historisation segment/région).
dim_date	date_key (PK), date_complete, mois, jour_semaine, est_weekend	Calendrier pré-calculé (features saisonnières).
dim_promotion	promo_key (PK), promotion_id, portee, cible, remise_pct, date_debut/date_fin	Pas de SCD (entité à durée de vie courte).

Annexe B — Guide « quelles tables pour quel modèle »

Cas d'usage	Tables principales	Idée de construction
Prévision de la demande	fact_ventes, dim_date, dim_produit, dim_promotion	Série temporelle par produit × jour (somme des quantités) + features calendaires et produit ; la promo est un

		signal exogène.
Simulation de remise	fact_ventes, dim_produit, dim_promotion, dim_date	Projeter volume, CA et marge pour un niveau de remise donné (baseline médiane produit) ; simulation, non causale ; le coût borne la marge.
Recommandation produit	fact_evenements_web, fact_ventes, dim_produit, dim_client	Collaboratif (matrice client × produit) + contenu (similarité catégorie/marque) ; hybride pondérant le funnel view→cart→purchase.

Rappels transverses : jointures sur les clés de substitution uniquement ; données déjà nettoyées (doublons, quantités négatives, FK orphelines retirées) ; promo_key nullable dans fact_ventes correspond au cas normal « vente sans promo », pas à une donnée manquante.

Annexe C — Registre des risques (rappel)

Voir le tableau détaillé au chapitre 21. Les risques de criticité élevée (R1, R2, R3, R6) font l'objet d'un suivi prioritaire ; leur nombre est l'un des indicateurs de pilotage du projet.

Annexe D — Cadence de référence (projet 10-12 semaines)

Sprint	Semaines	Objectif principal
Sprint 0	S1-S2	Cadrage, gouvernance data, architecture, jeu de données.
Sprint 1	S3-S4	Ingestion, data lake / warehouse, data quality.
Sprint 2	S5-S6	Prévision de la demande & simulation de remise.
Sprint 3	S7-S8	Recommandation hybride & évaluation.
Sprint 4	S9-S10	API, dockerisation, MLOps, dashboard.
Sprint 5	S11-S12	Business case, rapport, mise en production, bilan.

Annexe E — Glossaire

- **WBS** : Work Breakdown Structure — décomposition hiérarchique des travaux.
- **RACI** : Responsible, Accountable, Consulted, Informed — matrice des responsabilités.
- **CRISP-DM / TDSP** : méthodologies itératives de projet data (compréhension métier → déploiement).
- **ETL / ELT** : Extract-Transform-Load — pipeline d'alimentation des données.
- **SCD Type 2** : Slowly Changing Dimension — historisation des changements par insertion de nouvelles versions.
- **MLOps** : industrialisation du cycle de vie des modèles (CI/CD, monitoring).
- **CLTV** : Customer Lifetime Value — valeur vie client.
- **SPI / CPI** : indices de performance délai / coût (suivi de projet).

- **Uplift** : gain incrémental d'un modèle ou d'un traitement par rapport à une baseline.
- **Fuite de cible** : utilisation, comme variable d'entrée, d'une information postérieure à la prédiction — biais à proscrire.
- **XAI** : Explainable AI — explicabilité des modèles.